ДЗ 2: инструменты под нагрузкой

1. Экономика контекста

На шаге t вход стоит α(S + D) + ht. Суммирование от 1 до T даёт α(S + D)T + hT(T + 1)/2. При T + 1 ~ T получаем C ~ α(S + D)T + hT²/2. Отбрасывается линейный член hT/2; также используется приближение H_t ~ ht.

α	Префикс	История	Всего C	Доля истории
1	2 280 000	1 200 000	3 480 000	34,48%
0,1	228 000	1 200 000	1 428 000	84,03%

S = 2 000, D = 55 000, h = 1 500, T = 40; цена входного токена равна 1. Кэширование экономит 2 052 000 токен-эквивалентов (58,97%). Для одинакового относительного уменьшения параметров после кэширования сильнее h: снижение на 10% экономит 120 000, тогда как D - 22 000, α - 22 800. Без кэширования лидирует α (228 000 против 220 000 для D и 120 000 для h).

При d = 300, s = 500, k = 5 вариант B занимает 2 000 токенов. Условие 300N > 2 000 даёт минимальное N = 7. Точность B: 0,95 × 0,90 = 0,855; B перестаёт выигрывать при A(N) >= 85,5%. Оптимистичность: не учтены расходы поиска и возможного дополнительного вызова LLM; A(5) может быть ниже на похожих кандидатах, найденных поиском.

2. MCP-сервер

Домен - учебное расписание, данные вымышленные. Четыре инструмента: schedule_get, schedule_search, schedule_teacher, schedule_room. У параметров есть описания; response_format задан enum concise/detailed; дополнительные поля запрещены. Ошибки инструмента возвращают isError: true и подсказку. Сервер читает фиксированные данные и не создаёт состояния между вызовами: handle не требуется.

Лог MCP Inspector подтверждает server/discover, версию 2026-07-28, _meta в каждом запросе и вызовы всех четырёх инструментов. Результат pytest: 23 passed in 0.68s. Тесты включают оба режима, ошибки, схемы, LoopGuard и нестабильный инструмент.

Пример / cl100k_base	concise	detailed
get: lesson_1	55	75
search: 2026-10-10	101	139
teacher: А. Иванова	162	222

Подсчитан текст content, блоки соединены переводом строки, без оболочки MCP. Для экспериментов далее использована фактическая статистика токенов Qwen из LM Studio.

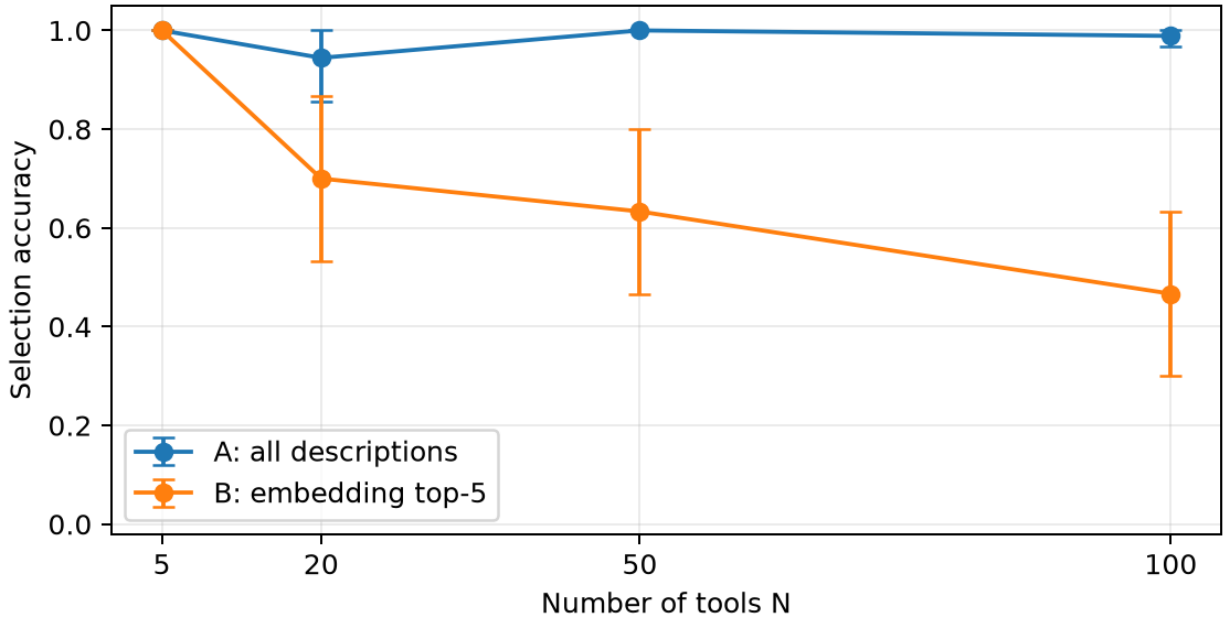
3A. Выбор инструмента

Модель: unsloth/qwen3.5-4b (4B, Q4_K_S), LM Studio, локальный запуск; загруженный контекст 16493 токена. Temperature = 0,3, максимум ответа 256 токенов, таймаут 60 с. В пилоте модель отвечала без текста рассуждений; тот же режим LM Studio сохранён в основном прогоне. Платных API нет.

Пул: 100 описаний, из них 4 настоящих инструмента и 96 синтетических отвлекающих; 24 относятся к экзаменам, консультациям, бронированиям и сменам. 30 размеченных запросов: 8 get, 8 search, 7 teacher, 7 room. Вложенные наборы N = 5, 20, 50, 100, seed 42; порядок описаний фиксирован и перемешан. Все четыре правильных инструмента присутствуют в каждом наборе.

A видит все N названий и описаний. B видит top-5 по косинусному сходству эмбеддингов paraphrase-multilingual-MiniLM-L12-v2. Поиск внешний и детерминированный, один вызов LLM в обоих вариантах; его вычислительная стоимость не входит в токены LLM. Наборы и поиск после пилота не изменялись.

720 попыток: 30 запросов × 3 повтора × 4 N × 2 варианта. Ошибки, неверный JSON и незавершённые ответы считаются неправильными; пилот исключён. 95%-е процентильные интервалы: 10 000 бутстрэп-выборок из 30 запросов; три повтора одного запроса всегда остаются вместе.



N	Верно A / 90	Верно B / 90	Recall@5	Вход A	Вход B
5	90	90	100.0%	173.2	173.2
20	85	63	73.3%	509.2	178.5
50	90	57	63.3%	1125.2	178.6
100	89	42	46.7%	2267.2	185.7

Технические/форматные ошибки: 0/720. Статистика входных токенов доступна для 720/720 запросов. Полные интервалы и таблицы: sol.ipynb; сырой вход и ответ каждой попытки: data.json.

При N = 100 точность A - 98.9%, B - 46.7%; Recall@5 - 46.7%. Поиск сокращает вход, но потеря правильного инструмента ограничивает точность B.

3B. Петли

20 задач: найти любое занятие на одну из двух разрешённых дат, получить его карточку и вернуть ID. Три условия, всего 60 эпизодов. Нестабильный schedule_search в 50% вызовов по seeded-генератору возвращает пустой content без ошибки; иначе выполняется настоящий инструмент. В условии hint вместо пустоты возвращается isError: true с текстом «Ничего не найдено; попробуйте другое значение date». schedule_get стабилен.

Бюджет - 10 вызовов LLM на эпизод, включая финальный ответ. Модель сама выбирает инструмент и аргументы. Seed нестабильности 300-319 одинаков для одной задачи во всех условиях; порядок эпизодов перемешан с seed 456. Одинаковы модель, промпт, температура и бюджет. Даты заданы в запросе пользователя; эталонные ID модели не передаются.

Использован точный код LoopGuard из лекции: max_same = 3, window = 6. Его сигнал передаётся модели с наблюдением, последующие действия выбирает модель. Guard считает повтор в окне; метрика петли отдельно проверяет >=3 одинаковых вызова подряд или A-B-A-B. Успех требует допустимый ID, действительно найденный поиском и полученный через get. Неудачные и незавершённые эпизоды остаются в знаменателе.

Условие	Петли / 20	Успех / 20	Шаги	Входные токены	Все токены
Пустой ответ	0	15	3.85	1636.8	1723.5
Пустой + guard	0	16	3.55	1424.2	1502.1
Подсказка, без guard	0	16	4.35	2074.4	2175.8

Петель не обнаружено ни в одном условии; LoopGuard ни разу не сработал. Эти данные не позволяют установить, что сильнее помогает против петель. Разницу успешности нельзя приписать guard, который не активировался. Изменение: guard - 0 эпизодов, подсказка - 0. Успешность: база 15/20, guard 16/20, подсказка 16/20. Это описательное сравнение на 20 задачах, не доказательство универсального преимущества.

Ошибки/прерывания: 3/60; исчерпание бюджета: 3/60. Полный учёт токенов: 60/60. Сырые пошаговые входы, ответы, случайные числа и наблюдения сохранены в data.json.

Три угрозы валидности

1. Синтетические данные: один маленький домен, запросы похожи, отвлекающие описания шаблонные. Результаты могут не переноситься на реальные задачи и большие MCP-каталоги.

2. Одна квантованная модель и один способ эмбеддингов. Поиск по коротким описаниям плохо учитывает ID, имена и отрицания; низкий Recall ограничивает B. Разные размеры и качество описаний тоже влияют на результат.

3. Маленькая выборка и искусственная нестабильность. Всего 20 задач с независимыми сбоями вероятности 0,5 и ограничением 10 шагов. Seed сбоя попарно одинаков, но число обращений и генерация LLM различаются; bootstrap части A отражает вариацию запросов, а не всех возможных пулов и моделей.

API-ключи не использовались.